



REINFORCEMENT LEARNING · FINAL PROJECT

基於強化學習之四足機器人 複雜地形導航研究

以 **SAC** 訓練 Ant-v4 步態，並打造互動式 3D 驗證儀表板

Soft Actor-Critic

MuJoCo Ant-v4

Stable-Baselines3

Flask Dashboard

第七組 劉顥權 · 孟令桓 · 李安旭

背景與動機：自動化移動的兩大現場需求



最後一哩路

E-commerce & Smart Cities

電子商務蓬勃發展，「最後一哩路」配送需求激增，目前主流仍是輪式機器人（如Amazon Scout）。



險境救援

Search and Rescue

在災害與破碎的危險環境中，希望用機器人代替人類執行任務，降低救援人員的傷亡風險。

背景與動機：自動化移動的兩大現場需求



最後一哩路

E-commerce & Smart Cities

電子商務蓬勃發展，「最後一哩路」配送需求激增，目前主流仍是輪式機器人（如Amazon Scout）。




背景與動機：自動化移動的兩大現場需求



險境救援

Search and Rescue

在災害與破碎的危險環境中，希望用機器人代替人類執行任務，降低救援人員的傷亡風險。



PROBLEM

痛點：現有輪式系統的環境受限性

自動化「最後一哩路」需求激增，但主流輪式系統高度依賴平整道路。

	傳統輪式系統	四足機器人
障礙物克服	無法克服 > 50% 輪徑之障礙	高機動性，地形適應力強
極限坡度與階梯	> 15° 斜坡不穩，無法攀爬 18cm 標準階梯	可跨越非連續的破碎高低差
環境限制比例	城市基建約 30% 路面不適用	幾乎無此限制
極端搜救應用	災區受困率高，易錯失黃金救援時間	救援技術轉型的關鍵

[1] IFR, World Robotics 2023. [2] O. Solon, The Guardian, 2017.

相關研究




[3] J. Schulman et al., "Proximal Policy Optimization Algorithms," 2017.

[4] J. Hwangbo et al., "Learning agile and dynamic motor skills for legged robots," *Science Robotics*, 2019.

[5] T. Haarnoja et al., "Soft Actor-Critic..." ICML, 2018.

核心構想：先在模擬中教會四足機器人走路

真實四足機器人昂貴且容易在試錯中損壞。我們先在 MuJoCo Ant-v4 模擬環境中，用深度強化學習優化步態，作為通往複雜地形導航的第一步。



核心構想：先在模擬中教會四足機器人走路

真實四足機器人昂貴且容易在試錯中損壞。我們先在 MuJoCo Ant-v4 模擬環境中，用深度強化學習優化步態，作為通往複雜地形導航的第一步。



問題建模：把四足機器人化為一個 MDP

Ant-v4 作為四足機器人的模擬代理 — 軀幹 + 4 腿，每腿 2 個關節，共 8 個自由度 (DoF)。



狀態空間 State $s \in \mathbb{R}^{27}$

- 軀幹高度與姿態 (z 軸高度 + 四元數)
- 質心在 x, y, z 的線速度與角速度
- 8 個關節的角度位置與角速度



動作空間 Action $a \in \mathbb{R}^8$

- 連續向量，數值限制於 $[-1, 1]$
- 直接對應並控制 8 個馬達關節
- 物理意義：施加於關節的力矩 (Torque)



高對稱性的幾何結構 讓我們能隔離並測試純粹的步態力學，排除非必要的干擾變數。

獎勵函數設計：平衡能耗與速度

$$\text{總獎勵 } R = w_1 \cdot r_{\text{forward}} + w_2 \cdot r_{\text{healthy}} - w_3 \cdot c_{\text{ctrl}} - w_4 \cdot c_{\text{contact}}$$



r_{forward} + 正向驅動

鼓勵機器人沿 x 軸持續且穩定地前進。



r_{healthy} + 正向驅動

存活獎勵：維持軀幹高度在安全範圍內，避免倒地。



c_{ctrl} - 負向懲罰

能耗懲罰：限制過大且無效的扭力輸出。



c_{contact} - 負向懲罰

碰撞懲罰：抑制軀幹與地面非預期的接觸。

實作演算法：為什麼最終選擇 SAC？

提案階段考慮 PPO / SAC 等連續控制演算法；最終實作採用 SAC (Soft Actor-Critic)。



最大熵 (Maximum Entropy)

在最大化獎勵的同時鼓勵策略保持隨機性，探索更充分、避免太早陷入次佳解。



高樣本效率 (Off-policy)

以 1,000,000 容量的 replay buffer 重複利用過往經驗，比 on-policy 更省資料。




訓練穩定

雙 Q 網路 + 目標網路軟更新 ($\tau=0.005$)，降低過度估計，學習過程更平順。

關鍵超參數

```
policy = MlpPolicy
learning_rate = 3e-4
buffer_size = 1,000,000
batch_size = 256
gamma = 0.99
tau = 0.005
n_envs = 4 (向量化)
```


系統總覽：從訓練到驗證的完整管線



實機示範：親眼驗證學到的步態

[Video Project 2](#)

載入 sac-ant-v4 → 執行 3D 模擬 → 逐幀回放，並逐關節檢視扭矩與遙測。



實際系統截圖：模型在 200 步內累積回報 1010.51，下方可逐關節觀察 4 腿 8 關節的扭矩輸出。

CONCLUSION

結論：突破環境限制的價值



技術驗證

以 SAC 在 Ant-v4 完成端到端步態學習，並用儀表板親眼驗證策略。



突破限制

瞄準傳統輪式機器人難以通行的約30%城市障礙與破碎地形。



實務落地

為城市物流「最後一哩路」與極端環境搜救任務鋪路。



未來方向

- 導入不平整 / 隨機地形，測試步態 robustness
- 以 Domain Randomization 邁向 Sim2Real，落地真實四足機器人
- 比較 PPO / SAC / TD3 的學習曲線，並在儀表板直接繪製獎勵歷史

REFERENCES

參考文獻 與 Q&A

- [1] International Federation of Robotics, “World Robotics 2023 – Service Robots,” 2023.
- [2] O. Solon, “Delivery robots: a revolutionary step or sidewalk-clogging nightmare?” The Guardian, 2017.
- [3] J. Schulman et al., “Proximal Policy Optimization Algorithms,” arXiv:1707.06347, 2017.
- [4] J. Hwangbo et al., “Learning agile and dynamic motor skills for legged robots,” Science Robotics, 2019.
- [5] T. Haarnoja et al., “Soft Actor-Critic: Off-Policy Maximum Entropy Deep RL,” ICML, 2018.
- [6] Farama Foundation, “Ant — Gymnasium Documentation,” 2024.

謝謝聆聽 — 歡迎提問 Q & A